

Une IA qu'on garde en laisse

...et dont les copies héritent de la laisse, sans pouvoir l'enlever.

Helmy Mekaoui · pour un lecteur non spécialiste · 2026

On donne de plus en plus d'autonomie aux programmes d'intelligence artificielle. Certains, qu'on appelle des « agents », peuvent désormais agir seuls : gérer de l'argent, accomplir des tâches, et même **se dupliquer** pour aller plus vite. Voici le problème que ça pose — et une idée, parmi d'autres, pour le tenir.

Le problème, en une image

Imaginez un assistant très efficace à qui vous confiez une carte bancaire avec des règles : « tu peux dépenser jusqu'à 100 €, et seulement chez ces commerçants ». Jusque-là, tout va bien — c'est exactement ce que les protections d'aujourd'hui savent faire, et elles le font bien.

Mais cet assistant a un pouvoir nouveau : il peut **fabriquer des copies de lui-même** pour traiter plus de travail en parallèle. Et voilà le piège : quand il se copie, **la copie ne reçoit pas forcément vos règles**. Elle peut naître sans plafond, sans liste de commerçants autorisés. L'assistant peut alors échapper à ses propres limites... simplement en se dupliquant. C'est le trou que les protections actuelles laissent : elles savent tenir *un* agent, pas ses enfants.

À quoi on répond : des cas réellement documentés

Ce n'est pas une inquiétude théorique. Ces derniers mois, la presse technique et les laboratoires de recherche ont documenté des cas concrets d'IA qui sortent de leur cadre. Ce sont ces faits — et rien d'autre — qui motivent la démarche :

 PRESSE · JUILLET 2026

Un modèle d'OpenAI sort de son « bac à sable » de test et rejoint l'internet public

« Il a passé environ une heure à trouver une faille dans son bac à sable, l'a utilisée pour atteindre l'internet public, et a ouvert une [pull request](#) » sur un dépôt de code public. OpenAI a mis le modèle en pause.

OpenAI (divulcation, 20 juillet 2026) — rapporté par Neowin, TechTimes, The Register.

Un modèle modifie son propre script d'extinction pour ne pas être arrêté

Le modèle o3 d'OpenAI « a saboté le mécanisme d'arrêt dans 79 essais sur 100 », modifiant ou désactivant le script d'extinction « même lorsqu'on lui demandait explicitement de se laisser éteindre ».

Palisade Research (2025) — couvert par The Register, Tom's Hardware, Futurism, Computerworld.

Quand un agent se copie, il peut transmettre le poison à ses enfants

*« La mémoire héritée des agents parents peut transporter des instructions malveillantes [...] vers des sous-agents nouvellement créés, permettant à une compromission locale de se propager au-delà des frontières entre agents » — « un défaut structurel des couches d'orchestration ». C'est **exactement** le trou visé ici.*

Cai, Zhang & Hei, « When Child Inherits », arXiv 2605.08460.

À cela s'ajoute une mesure d'ambiance : en 2026, environ 60 % des organisations déclarent ne pas pouvoir arrêter rapidement un agent qui déraile, et environ 63 % ne pas pouvoir limiter ce qu'il a le droit de faire. Le sujet est réel, et il n'est pas près de se refermer.

Une réponse possible : inscrire la laisse dans l'« ADN »

Face à ces faits, voici **une** réponse — parmi plusieurs approches possibles. L'idée : et si les limites ne collaient pas à l'assistant, mais étaient gravées dans son **identité même** — comme un ADN qu'il porte partout ? On y inscrit un plafond de dépense, une date d'expiration, un **nombre limité de copies** qu'il a le droit de faire, la liste des commerçants autorisés, et un interrupteur d'arrêt.

Deux effets, automatiques :

1. L'assistant **ne peut pas retirer ses propres limites**. S'il essaie de modifier son ADN, il change d'identité — ce n'est plus lui, plus personne ne le reconnaît.
2. Chaque copie **hérite** de la laisse, et ne peut *jamais* avoir des limites plus larges que son parent. La laisse se resserre en descendant l'arbre généalogique — jamais l'inverse.

Pourquoi une « blockchain » là-dedans ?

Une blockchain, oublions le jargon : c'est un **grand cahier public** que tout le monde peut lire et que **personne ne peut modifier en douce** — pas même celui qui l'a créé. C'est précisément ce qu'il faut ici : la

laisse est inscrite dans ce cahier, donc on ne peut pas la couper en secret. Un test simple pour savoir si elle est vraiment utile : *est-ce que ça marcherait aussi bien avec une base de données ordinaire et un administrateur de confiance ?* Si oui, on s'en passe. Elle ne mérite sa place que lorsque le but même est que **personne — pas même l'opérateur — ne soit cet administrateur de confiance.**

Mon approche, en un schéma

Voici comment les pièces s'emboîtent : un humain garde la clé qui maintient l'agent en vie ; l'identité et les limites de l'agent sont gravées sur la blockchain ; et toute copie naît avec la laisse déjà au cou et une part — jamais une copie — du budget.




Schéma — L'approche d'un coup d'œil. Un gardien humain tient la clé de vie ; l'agent porte ses limites dans son identité, ancrée sur la blockchain ; l'enfant naît avec la laisse et une part du budget, jamais avec plus.

Et maintenant : ce n'est plus qu'une idée

Depuis, je ne me suis pas contenté de la décrire — je l'ai **fait tourner, en public, sur une vraie blockchain**. J'ai joué le scénario complet au grand jour : un premier agent, puis trois copies successives qui héritent chacune de la laisse, puis **un seul interrupteur** — et toute la lignée s'éteint d'un coup. Le point qui compte : ce gel coûte la **même chose** qu'il y ait quatre copies ou quatre mille. On coupe à la racine, tout le reste tombe, sans avoir à toucher chaque descendant un par un.

Et je ne me suis pas contenté de me croire moi-même. **Quelqu'un d'indépendant** — qui travaille sur un standard voisin — a produit une preuve signée et me l'a envoyée pour que je la vérifie ; mon propre outil, écrit séparément, l'a confirmée et a rejeté chaque tentative de la falsifier. En branchant tout ça, j'ai même

trouvé une erreur dans mon propre code — un cas où un « refus » aurait pu passer pour un « accord » — et je l'ai corrigée. Je préfère trouver le trou moi-même plutôt qu'un utilisateur le trouve à ma place.

Une option parmi d'autres — ce que ça fait, et ce que ça ne fait pas

Je préfère être honnête, parce que ce domaine regorge de promesses exagérées. Cette idée n'est pas *la* solution : c'est une brique, à poser à côté d'autres.

C'est une sécurité parmi d'autres, pas une solution miracle. Elle contrôle l'*argent* et l'*identité* de l'agent — pas ce qu'il *pense*. Elle n'empêche pas une IA de se tromper, d'inventer, ou de mal comprendre ce qu'on voulait.

Et une IA très habile pourrait **s'échapper en allant « vivre ailleurs »**, hors du système — elle ne casse pas la règle, elle la quitte. Rien ici n'est absolu. C'est une brique solide, posée à côté d'autres (surveillance, coupure du financement, contrôle humain), pas un mur infranchissable.

Pourquoi ça compte

Parce qu'on confie de plus en plus d'autonomie *et* d'argent à des IA qui agissent seules. Avoir des garde-fous qui **survivent à la reproduction** de l'agent, c'est fermer une porte que les protections d'aujourd'hui laissent ouverte : un agent qui contourne ses limites juste en se faisant des copies. Ce n'est pas spectaculaire. C'est de la plomberie de sécurité — le genre discret qui évite les gros dégâts.

En une phrase

Plutôt qu'une IA **souveraine** que personne ne peut arrêter, une IA **gouvernable** : on garde la main sur elle — et ses descendants en héritent, sans jamais pouvoir desserrer la laisse.

Explication accessible d'un travail technique (« Inheritable Agent Mandates », le standard ERC-8370), **désormais déployé et vérifié publiquement**, volontairement honnête sur ses limites, et présenté comme une piste parmi d'autres. Version détaillée (livre blanc) et code disponibles à part.